Individuell inlämningsuppgift – Machine Learning

Case: California Housing – modellering som beslutsunderlag

Mål & valt spår

Målet med uppgiften är att bygga en reproducerbar maskininlärningsmodell som kan förutsäga och uppskatta bostadsvärdet baserat på tillhandahållen information. Modellen ska fungera som ett beslutsstöd för kommuner och fastighetsaktörer genom att ge en snabb värdering av bostadsområden baserat på deras egenskaper.

Jag valde spår A eftersom det bäst uppfyller uppgiftens syfte att ge en korrekt och kontinuerlig prognos för bostadsvärden.

Dataförståelse och EDA

Datasetet innehåller 9 kolumner med 8 feature (longitude, latitude, housing_median_age, total_rooms, total_bedrooms, population, households, median_income) samt target median_house_value. California Housing Dataset innehåller 20640 rader och 10 kolumner. Det finns både flera numeriska och en kategoriska variabler. Kategorisk variabel ocean_proximity visar avstånd till kusten.

I den inledande dataanalysen såg jag ett tydligt positivt samband mellan medianinkomst och medianhusvärde, vilket tyder på att områden med högre medianinkomster tenderar att också ha högre bostadsvärden. Saknade värden: Den enda kolumnen total_bedrooms har 207 saknade värden som jag har fyllt i med medianen.

Korrelationsanalysen visar att medianinkomsten är den starkaste prediktorn för husvärde (0,69), medan de flesta andra variabler har svaga individuella samband. Höga korrelationer mellan variabler som rum, sovrum och hushåll stöder användningen av feature engineering och trädbaserade modeller som Random Forest.

Data Split & Preprocessing:

Data delades upp med 80 procent för träna modellen och 20 procent för tästa. Förbehandling implementerades med hjälp av en pipeline för att undvika dataläckage.

Feature engineering:

Jag skapade 3 nya feature (feature engineering):
- rooms_per_household = total_rooms / households
- bedrooms_per_room = total_bedrooms / total_rooms
- population_per_household = population / households

I den numeriska pipelinen har jag använt SimpleImputer för att hantera saknade värden i de numeriska variablerna. och StandardScaler funktionen för att skala numeriska variabler till samma skala. .

För den kategoriska pipelinen har jag använt OneHotEncoder funktionen för att omvandla kategoriska variabler till numeriska.

Kombinationen av SimpleImputer, StandardScaler och OneHotEncoder säkerställer att datan är kompletta, jämförbara och i ett format som modellerna kan hantera effektivt. Detta bidrar till en mer robust och tillförlitlig modell.

Träna Modellen

Tre modeller (Linear Regression, Random Forestm och Decision Tree) tränades och jämfördes med 5-fold cross validation.

Resultat från Cross Validation:

Modell	RMSE (CV)	MAE (CV)
Random Forest	50 216	32 914
Linear Regression	67 849	48 872
Decision Tree	71 836	45 831

Välj och optimera(Hyperparameter Tuning) en modell

Root Mean Squared Error (RMSE) valdes som primärt utvärderingsmått eftersom det bestraffar stora prediktionsfel hårdare än andra mått, vilket är viktigt vid uppskattning av bostadspriser där betydande avvikelser kan ha en betydande ekonomisk inverkan. RMSE uttrycks också i samma enheter som målvariabeln, vilket gör den intuitiv för tolkning.

Random Forest valdes som slutgiltig modell eftersom den uppnådde den lägsta RMSE under cross validation

Cross validation med 3-faldiga justeringar användes under hyperparameter tuning för att minska beräkningstiden för Random Forest-pipelinen. Medan RMSE användes som det primära utvärderingsmåttet, ansågs MAE också ge ytterligare insikt i genomsnittligt prediktionsfel. Denna kombination erbjuder en solid, datadriven grund för beslutsfattande.

Jag har testat med följande hyperparametrar:
- n_estimators [50, 100] – antal träd i skogen, fler träd ger stabilare förutsägelser men tar längre tid att träna.
- max_depth [None, 10, 20] –hur djupt träden tillåts växa. Det begränsar överfitting.
- min_samples_split [2, 5] – minsta antal samples för att dela en nod, också för att begränsa overfitting

Från optimering fick jag de bästa parametrar:

n_estimators = 100
max_depth = None (vilket är default för Random Forest)
min_samples_split = 2 (default för Random Forest)
Att max_depth och min_samples_split landade på defaultvärden tyder på att Random Forest inte behöver extra regularisering på den här datan. Modellen generaliserar redan bra utan begränsningar.

Resultat och rekommendation

Model	RMSE (cv)	MAE (cv)	RMSE (test)	MAE (test)
Random Forest	50215.589142	32913.939374	50390.876076	32388.168076
Linear Regression	67848.831225	48871.935207	NaN	NaN
Decision Tree	71835.726925	45830.701788	NaN	NaN

Resultaten från modelljämförelsen visar tydligt att Random Forest är den mest lämpliga modellen för att förutsäga medianbostadsvärden i Kalifornien. Modellen uppnådde lägst fel både i cross validation (RMSE ≈ 50 216) och på testdata (RMSE ≈ 50 391), vilket indikerar god generaliseringsförmåga och stabil prestanda.

Jämfört med Linear Regression och Decision Tree presterar Random Forest bättre eftersom den kan hantera icke-linjära samband och komplexa interaktioner mellan variabler.

Risker & begränsningar

Det finns flera viktiga begränsningar i denna analys som bör beaktas vid tolkning av resultaten.

För det första är datasetet aggregerat per geografiskt område och inte på individnivå. Detta innebär att modellen endast kan ge uppskattningar på områdesnivå och inte är lämplig för att exakt värdera enskilda bostäder. Variationer inom ett område fångas därmed inte upp.

För det andra finns det indikationer på att målvariabeln (median_house_value) har ett övre tak i datan (500 001). Detta kan leda till att modellen underskattar värdet i de dyraste områdena, eftersom den inte har tillgång till verkliga värden över denna gräns.

En annan viktig begränsning är även om modellen presterar bra på testdata kan den fungera sämre på ny data som skiljer sig från träningsdatan, till exempel vid förändringar i marknaden eller i andra geografiska områden.

Slutligen saknar datasetet flera potentiellt viktiga faktorer, såsom skolkvalitet, kriminalitet, infrastruktur och framtida utveckling. Detta innebär att modellen inte fångar hela komplexiteten i bostadsmarknaden.

Oövervakad inlärning
PCA Visualisering(två dimensioner) förklarade 54,7 % varians. K-means grupperar områden med liknande egenskaper och visar möjliga segment i datan. PCA och Kmeans visar vissa mönster och kluster i datan. PCA visar vissa klustermönster men ingen tydlig separation, vilket indikerar komplexa samband i data. KMeans grupperar data i tre segment, men kluster överlappar varandra och varierar i storlek. Detta tyder på att datamängden inte är naturligt separerbar, vilket stöder användningen av mer flexibla modeller som Random Forest.

Självreflektion
Under den här uppgiften anser jag att jag presterade bra i implementeringen av ett komplett och strukturerat arbetsflöde för maskininlärning från data preprocessing till modellutvärdering.

Jag insåg också att modellvalet är viktigt, eftersom mer komplexa modeller som Random Forest kan fånga mönster bättre än enklare.En av de mest utmanande delarna var att välja och utvärdera modeller korrekt. Vid modelloptimering var det svårt att avväga mellan bästa resultat och tidskrav för att köra med höga model__n_estimatorer. Jag har försökt med höga värden som 200, 300 men det var så tidskrävande att jag har valt att tästa 50, 100.

Till slut kan jag säga att jag lärde mig av det här projektet hur maskininlärning kan omvandla rådata till handlingsbara insikter för verkliga beslutsfattande.

Jag anser att min inlämning ligger nära en VG-nivå. Detta beror på att jag inte bara uppfyllde de grundläggande kraven (G), utan också gick längre genom att jämföra flera modeller på ett strukturerat sätt, tillämpa funktionsutveckling,använda pipelines för korrekt förbehandling, utföra hyperparameter testing inklusive ytterligare analys såsom PCA och ge tydlig motivering och tolkning av resultaten.

Som nästa steg kan vi testa mer avancerade modeller, såsom Gradient Boosting, som kan ge bättre prediktiv prestanda än Random Forest.